Введение в анализ данных в образовании

- Анализ данных в современном мире. Его роль при построении систем ИИ.
- Анализ данных в образовании. Цели и задачи.
- Этапы анализа данных. Задачи анализа данных
- Сбор данных. Открытые платформы данных.
- Формат хранения и представления данных для анализа.

Анализ данных в современном мире

Анализ данных — это процесс очистки, изменения и обработки необработанных данных, а также извлечения полезной и актуальной информации, которая помогает предприятиям принимать обоснованные решения.

Анализ данных представляет собой процесс получения информации путем создания моделей и применения математического аппарата (точнее статистических законов) для поиска закономерностей.

Процедуры анализа данных помогают снизить риски, связанные с принятием решений, предоставляя полезную информацию и статистику, часто представленную в виде диаграмм, изображений, таблиц и графиков.

Образовательные данные могут быть представлены в разных форматах. Можно выделить следующие случаи анализируемх данных:

- **Большие данные**. Большие данные определяются как огромный набор данных, который со временем продолжает расти в геометрической прогрессии. Четыре основные характеристики больших данных : объем, разнообразие, скорость и изменчивость. Объем описывает количество, скорость относится к скорости роста данных, а разнообразие указывает на разные источники данных. Достоверность говорит о качестве данных , определяя, представляют ли они ценность для бизнеса или нет.
- **Структурированные/неструктурированные данные**. Структурированные данные — это предопределенная модель данных, такая как традиционная база данных со столбцами строк. Неструктурированные данные поступают в формате, который не помещается в строки и столбцы, и могут включать в себя видео, фотографии, аудио, текст и многое другое. Сравнение структурированных данных с неструктурированными показывает, что структурированными данными легче управлять и анализировать.
- **Поток даннывх или данные в режиме реального времени**. Данные, которые представляются, как только они получены, известны как данные в реальном времени. Этот тип данных полезен, когда решения требуют самой последней информации. Например, в режиме реального времени необходимо анализировать работу студентов с онлайн-курсом или результаты коворкинга.

Место анализа данных в построении систем ИИ

Иерархию задач, которые необходимо решать при решении задач машинного обучения, созда ния искусственного интеллекта хорошо отображает рис..

На рис. мы видим большое количество задач, которые надо решить, прежде чем удастся со- здать "умную"программу, решающую задачу машинного обучения или построения искусственного интеллекта. Эти задачи располагаются на самой вершине пирамиды задач. Более того, ширина горизонтального сечения слоя пирамиды отражает тот факт, что трудо- емкость задач внизу гораздо больше, чем трудоемкость задач вверху пирамиды.

Рассмотрим задачи, начиная с онования пирамиды.

Задача 1 (Collect data: сбор данных). В самом низу пирамиды находятся задачи по получе- нию данных с раздичных сенсоров, логгирование процессов, сбор данных с различных внешних источников и в том числе из опросов экпертов и пользователей систем.

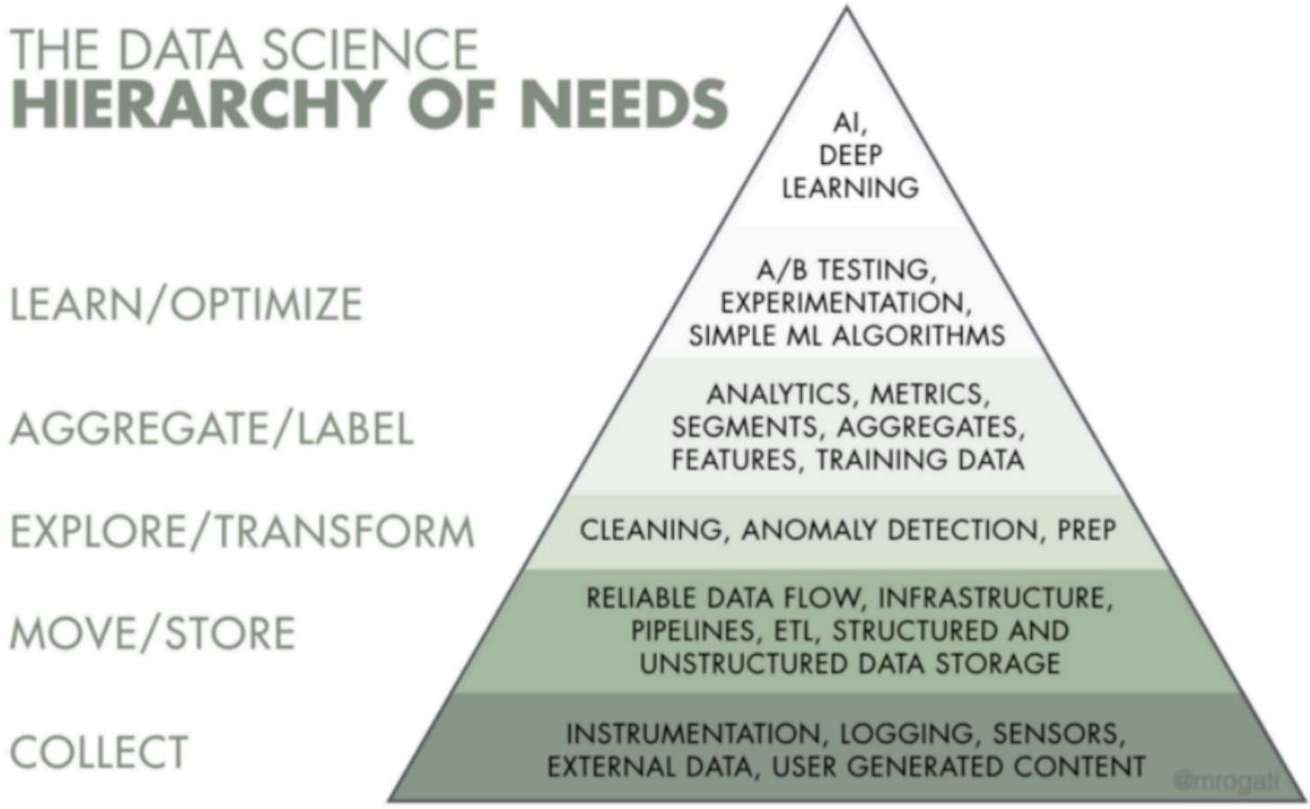

Например, в рамках проекта "Умный Дом"требуется поставить в доме и вокруг него различные сенсоры, датчики, вебкамеры, фиксировать звуки и команды людей, собирать отзывы о качестве работы системы.

Задача 2 (Move/Store: первоначальная очистка и накопление, хранение, структурирование). После получения данных требуется эти данные где-то накапливать и хранить, предварительно проверяя их надежность и отсеивая неинформативные данные.

Это задача связана с использованием облачных сервисов, на которых накапливаются данные. При этом имеет смысл уже на этом этапе предобрабатывать сырые данные. Например, если весь видеопоток со всех камер накапливать в течении нескольких суток, то это может занять сот- ни терабайтов информации. И при этом событийных моментоа, ради которых ведется фиксация может быть очень немного. Поэтому имеет смысл кодировать и запоминать только изменения в картинках, а не сами картинки.

Задача 3 (Explore/Transform: разведка/преобразование). на этом этапе происходит очистка данных и их первичная предобработка перед последующим анализом. Поэтому на этом этапе могут выявляться аномалии, которые могут внести серьезные искажения в результаты дальнейшего анализа данных с целью их фильтрации или сглаживания.

Например, нет смысла хранить результаты сбоев видеокамер и других процессов, которые не несут никакой информации. Недостоверные или искаженные данные. Резкие звуки или хлопки, хрипы, которые могут сопровождать запись голоса нужно вырезать или уменьшить, отфильтро- вать.

Задача 4 (Aggregate/Label: агрегирование/разметка). на данном этапе происходит анализ и подготовка данных для использвоания в алгоритмах машинного обучения. Данные анализируют- ся, кластеризуются, агрегируются, размечаются

Например, чтобы обучить "Умный дом"правильно реагировать на команды хозяина, необхо- димо собрать образцы голосовых команд, разметить их (т.е. указать, какая команда была произ- несена), закодировать и проанализировать насколько хорошо произнесены команды и насколько их можно отличить от других команд, или от команд, произнесенных другими людьми.

На данном этапе необходимо определить основные метрики, которые могут быть испльзуемы для того, чтобы понять насколько хорошо решение той или иной задачи. Т.е. выделить числовые критерии качества решения задач.

Основные задачи аналитика - это задачи 3 и 4. Задачи сбора и хранения даннных решаются на образовательных порталах, на современных образовательных платформах.

Анализ данных в образовании

Анализ данных в образовании — это использование машинного обучения, статистики и Data Mining для обработки информации из учебных платформ (курсы, электронные журналы) с целью персонализации обучения, прогнозирования успеваемости и оптимизации учебных программ. Он помогает выявлять пробелы в знаниях, снижать отсев студентов и повышать эффективность методик обучения.

Особенно остро необходимость в анализе данных появилась после массового применения онлайн-курсов, на которых иногда обучаются одновременно десятки тысяч пользователей.

Основные направления применения анализа данных в образовании:

- Персонализация обучения (адаптивное обучение): Автоматическая корректировка учебных программ под уникальные потребности, темп и способности каждого студента.
- Прогнозирование успеваемости: Выявление учащихся «в зоне риска» (с риском отчисления или низкой успеваемости) на основе анализа их поведения, посещаемости и оценок, что позволяет педагогам вовремя вмешаться.
- Анализ образовательного контента: Оценка эффективности использования мультимедийных ресурсов, электронных учебников и онлайн-курсов.
- Оптимизация процессов и бюджета: Улучшение административного планирования, управление расходами и разработка новых образовательных продуктов.

Типы данных, подлежащие анализу

- Персональные данные: Базовая информация об учащемся.
- Данные об обучении: Взаимодействие с контентом (время просмотра, результаты тестов, скорость прохождения модулей).
- Административные данные: Посещаемость, пропуски, зачеты.

Инструменты и технологии:

Аналитика часто реализуется с помощью языка Python (библиотеки, Jupyter Notebook, Google Colab), специализированных инструментов анализа даннных, а также платформ хранения и обработки данных, таких как Hadoop.

Этапы анализа данных. Задачи.

Этапы анализа данных включают в себя сбор всей информации, ее обработку, изучение данных и их использование для поиска закономерностей и других идей. Процесс состоит из:

- **Сбор требований к данным:** спросите себя, почему вы проводите этот анализ, какой тип анализа данных вы хотите использовать и какие данные вы планируете анализировать.
- **Сбор данных:** руководствуясь определенными вами требованиями, пришло время собирать данные из ваших источников. Источники включают тематические исследования, опросы, интервью, анкеты, прямое наблюдение и фокус-группы. Обязательно систематизируйте собранные данные для анализа.
- **Очистка данных:** не все данные, которые вы собираете, будут полезны, поэтому пришло время их очистить. В этом процессе вы удаляете пробелы, повторяющиеся записи и основные ошибки. Очистка данных обязательна перед отправкой информации на анализ.
- **Анализ данных:** здесь вы используете программное обеспечение для анализа данных и другие инструменты, которые помогут вам интерпретировать и понимать данные и делать выводы. Инструменты анализа данных включают Excel, Python , R, Looker, Rapid Miner, Chartio, Metabase, Redash и Microsoft Power BI.
- **Интерпретация данных:** теперь, когда у вас есть результаты, вам нужно их интерпретировать и предложить наилучший план действий на основе ваших выводов.
- **Визуализация данных:** визуализация данных — это причудливый способ сказать: «графически покажите свою информацию так, чтобы люди могли ее прочитать и понять». Вы можете использовать диаграммы, графики, карты, маркеры или множество других методов. Визуализация помогает получать ценные сведения, помогая сравнивать наборы данных и наблюдать за взаимосвязями.

Виды анализа данных

Сегодня доступно полдюжины популярных типов анализа данных, обычно используемых в мире технологий и бизнеса. Они есть:

- **Описательный:** описательный анализ работает отвечает на вопрос: «Что происходит?». Он описывает происходящий процесс, иллюстрирует средние значения и отклонения в непрерывных данных, а также проценты и частоты в категориальных данных.

Данный анализ используется для решения задач мониторинга учеюного процесса. Рассчитываются средние баллы, процент (НЕ)успевающих в группе по результатам аттестации, процент посещения занятий, ...

- **Диагностический анализ:** диагностический анализ отвечает на вопрос: «Почему это произошло?» Используя информацию, полученную в результате статистического анализа (подробнее об этом позже!), аналитики используют диагностический анализ для выявления закономерностей в данных. В идеале аналитики находят аналогичные модели, существовавшие в прошлом, и, следовательно, используют эти решения для решения текущих проблем.

Например, на заре внедрения онлайн-курсов и онлайн-обучения (в 2012-2016 гг) многие разработчики онлайн-курсов обращались к аналитикам с вопросом "Почему так мало обучающихся завершают успешно их онлайн-курс?", "В чем состоит камень преткновения?" "Почему они бросают его на полпути?". "Как уулучшить курс?", "Что вообще происходит на курсе?". Примеры ОК УрФУ (Open EDU), ТГУ(Coursera), МФТИ(Coursera), ВШЭ (Coursera).

- **Предиктивный анализ:** предиктивный анализ отвечает на вопрос: «Что, скорее всего, произойдет?» Используя закономерности, обнаруженные в старых данных, а также в текущих событиях, аналитики предсказывают будущие события. Хотя не существует такой вещи, как 100-процентно точный прогноз, шансы улучшаются, если у аналитиков есть много подробной информации и дисциплина для ее тщательного исследования.

Например, в ЦЭО Волгатеха анализировали результаты обучения на эл. курсах после 1-й аттестиации (8-я неделя обучения, экватор) и прогнозировали итоговые результаты (процент успевающих после сессии).

- **Статистический анализ:** статистический анализ не только углубляет ответ на вопрос: «Что произошло?» и "почему произошло", он анализирует взаимосвязи. Таким образом, это важная составляющая и описательного и предиктивного и диагностического анализа. В статистическом анализе выделяют несколько подкатегорий: корреляционный анализ, регресиионный анализ, проверка гипотез.
- **Анализ текста:** также называемый « интеллектуальным анализом данных », анализ текста использует базы данных и инструменты интеллектуального анализа данных для обнаружения шаблонов, находящихся в больших наборах данных. Он преобразует необработанные данные в полезную бизнес-информацию. Анализ текста, пожалуй, самый простой и прямой метод анализа данных.

Данный анализ может быть использован для анализа и оценки ответов - эссе студентов, их письменных работ. Можно сравнивать ответы с шаблонами ответов или заполнять чек-лист наличия в ответе каких-то важных деталей.

- **Предписывающий анализ:** используйте все типы анализа, сравните результаты анализа с нормативными показателями, сделайте выводы, рекомендации и вы получите предписывающий анализ.

Такой анализ очень часто полезен для создателей онлайн-курсов, для создателей тестов. Диагностика показывает в чем проблема тестового задания (слабая дифференциация, слишком легкое задание, ...) и рекомендательная система предписывает как это можно исправить.

Сбор данных. Открытые платформы данных.

Наборы открытых данных Министерства просвещения Российской Федерации.

Платформы Kaggle, World Bank Education Statistics,

Kaggle - платформа для решения задач ML и соревнований

ссылка на платформу: https://www.kaggle.com/

На платформе **Kaggle** владелей задачи может ее зарегистрировать и объявить конкурс.

На странице задачи размещаются следующие вкладки:

- Overview: описание задачи, условия конкурса, как протестировать свое решение, призы.
- Data: Описание датасета, файлы, признаки, целевые паарметры, обучающий датасет, датасет для тестирования. Отсюда можно скаать данные или посмотреть скрипт как его можно загрузить.
- Code: Примеры блокнотов, в которых представлено возможное решение задачи.
- Discussuib: блоги обсуждения решений задачи.
- Leaderboard: хит-парад решений, рейтинги участников сорвенования.
- Rules: правила соревнований. Пока вы их не примете, данные вам не будут доступны.

см. пример: https://www.kaggle.com/competitions/riiid-test-answer-prediction/data

```
Напишите программный код или сгенерируйте его с помощью искусственного интеллекта.
```

World Bank Education Statistics

The World Bank EdStats Portal (Education Statistics Portal) is a platform to allow for easy access to data for key indicators in education covering topics such as access, completion, learning outcomes, expenditures, policy, and equity.

EdStats is currently being revamped to improve user experience and relevance so certain indicators may not be up to date.

The EdStats dataset as well as other education databases remain accessible in the meantime.

https://datatopics.worldbank.org/education/wRsc/about

https://databank.worldbank.org/source/education-statistics-%5E-all-indicators

Наборы открытых данных Министерства просвещения РФ

Наборы открытых данных Минпросвещения России предоставляют структурированную информацию о сфере образования в машиночитаемом формате, доступном для использования. Они включают перечни профессий, графики олимпиад, данные о вакансиях, педагогических вузах и статистику. Основной источник — официальный портал открытых данных министерства.

Ключевые наборы открытых данных, представленные на opendata.edu.gov.ru, включают:

- Профессиональное образование: Перечни профессий и специальностей среднего профессионального образования, перечень профессий рабочих и должностей служащих для профессионального обучения.
- Олимпиады и мероприятия: Графики проведения заключительного этапа Всероссийской олимпиады школьников.
- Кадровые вопросы: Сведения о вакантных должностях государственной гражданской службы в Минпросвещения России.
- Педагогическое образование: Информация о деятельности педагогических вузов страны.

ПРример данных:

https://opendata.edu.gov.ru/opendata/7710539135-ege

Формат хранения и представления данных для анализа.

Большинство данных хранятся в реляционных базах данных в виде связанных таблиц. Мржно получить одну таблицу данных или связать несколько таблиц в одну таблицу в формате xls, xlsx или в формате csv.

Формат CSV

В формате csv данные хранятся в текстовом виде и могут легко просматриваться человеком. Пример таких данных можено видеть на сайте открытых данных Минобра - результаты ЕГЭ (https://opendata.edu.gov.ru/opendata/7710539135-ege):

```
"region","count_vyp","count_participant","count_100ball"
"Республика Адыгея","2833","3232","5"
"Республика Башкортостан","25731","28138","27"
"Республика Бурятия","6890","7547","15"
"Республика Алтай","1694","2180","2"
...
```

1-я строка такого файла может содержать названия столбцов (параметров). Каждая следующая строка содержит занчения этих параметров для какого-либо объекта. Обычно значения перечисляются через запятую. Но могут быть и другие варианты - через точку с запятой или через знак табуляции, через пробел и т.д.

Данный формат чаще всего используется для экспорта данных из баз данных платформ. Могут быть и другие варианты.

Мы, в дальнейшем будем предполагать, что наши данные уже при=едставлены в виде таблиц и хранятся в файле формата CSV или xlsx (xls).

Загрузка данных для анализа

ЧТобы начать работать с данными их нужно:

- откуда-то записать на доступный вам локальный или облачный рабочий диск в виде файла;
- загрузить данные из файла в оперативную память.

Чтобы решить 1-ю задачу, мы будем либо сами выгружать файлы из облаков и загружать на наши рабочие диски. Либо будем испльзовать API (интерфейсы) этих облачных хранилищ данных.

Например, файл "data-20150609T145241-structure-20121127.csv" я загрузил на свой рабочий компьютер и затем перенес на облачный гугл-диск в папку "/content/drive/My Drive/Colab Notebooks/teacher/EducationDA/data"

Чтобы решить 2-ю задачу, мы будем пользоваться готовыми функциями из специализированных библиотек работы с данными. Ниже они перечислены и описаны (pandas, numpy) или API облачных хранилищ.

```
# Пример загрузки данных из файла из гугл-диска
path = "/content/drive/My Drive/Colab Notebooks/teacher/EducationDA/data/" # путь к папке, где хранится файл с данными
datafile = "data-20150609T145241-structure-20121127.csv"  # имя файла

# Подключаем наш гугл-диск к облачной среде Google Colab
from google.colab import drive
drive.mount("/content/drive/")

# загружаем данные из файла с использованием библиотеки pandas
import pandas as pd

data = pd.read_csv(path + datafile)
data.head()
```

```
Mounted at /content/drive/
```

	region	count_vyp	count_participant	count_100ball
0	Республика Адыгея	2833	3232	5
1	Республика Башкортостан	25731	28138	27
2	Республика Бурятия	6890	7547	15
3	Республика Алтай	1694	2180	2
4	Республика Дагестан	25944	27338	7

Далее: New interactive sheet

```
data.describe()
```

	count_vyp	count_participant	count_100ball
count	83.000000	83.000000	83.000000
mean	9450.819277	10736.602410	43.012048
std	8605.794626	9630.834804	78.888543
min	255.000000	349.000000	0.000000
25%	4238.000000	4868.500000	7.500000
50%	6253.000000	7180.000000	24.000000
75%	12358.000000	13873.000000	45.000000
max	55856.000000	62983.000000	654.000000

Напишите программный код или сгенерируйте его с помощью искусственного интеллекта.

Пакеты Python для анализа данных

Чтобы провести анализ данных в Python за минимальное время, мы должны сначала познакомиться с основными пакетами (библиотеки).

Библиотека Python - это набор функций и методы, которые позволяют выполнять множество действий без написания кода. Библиотеки обычно содержат встроенные модули, содержащие разные функции, которые можно использовать, вызвав определенный метод библиотеки.

Все библиотеки анализа данных Python делятся на четыре группы, в которых представлены библиотеки, позволяющие решать задачи разной уровни сложности:

Бюблиотеки обработки данных

Первая группа называется научными **вычислительными библиотеками**. Сюда относится библиотека **Pandas**. Она является одной из частоиспользуемых библиотек при работе с большими данными. Библиотека Pandas предполагает работу со структурами данных и предоставляет инструментарий эффективного манипулирования данными и их анализа.

pandas

Pandas отлично проявляет себя в сферах статистики, анализа данных, экономики, финансов. **Основная задача библиотеки - очистка и первичная оценка данных по общим показателям**. Инструментом библиотеки является двухмерная таблица,

состоящая из меток столбцов и строк и называя **фреймом данных (DataFrame)**. Имеется поддержка объекта DataFrame, предназначенного для работы с индексированными массивами и позволяющий работать с различными форматами данных: начиная от CSV до TSV.

Библиотека уверенно справляется с обработкой больших объёмов данных и при необходимости использует возможности NumPy и SciPy. Впрочем именно взаимодополнение этих пакетов и привело к тому, что чаще всего их используют вместе. Pandas позволяет:

- Обменивать данные между структурами в памяти и файлами различных форматов;
- Переформатировать наборы данных (даже создавать сводные таблицы);
- Выполнять трёхэтапные операции типа «разделение, изменение, объединение»;
- Работать с временными рядами: формирование временных периодов и изменение интервалов.

Библиотека NumPy - это один из основных пакетов программного обеспечения научной библиотеки приложений для обработки больших многомерных массивов и матриц, большой набор расширенных математических функций и методов реализации которых, позволяет этим объектам выполнять операции. Лучшая и самая важная особенность Numpy — **интерфейс массива**.

Его можно расширить до объектов для матриц и с небольшим изменением кода разработчики быстрее выполняют обработку. Этот интерфейс можно использовать для выражения изображений, звуковых волн и других двоичных необработанных потоков в виде массива действительных чисел в n-мерном формате. В общем, библиотека полезна для full-stack разработчиков, занимающихся задачами машинного обучения.

В NumPy (Numerical Python) встроено множество вычислительных механизмов. К таким особенностям можно отнести:

- Возможность использования и выполнения простых и достаточно сложных научных расчётов;
- Поддержка многомерных массивов;
- Множество встроенных методов для выполнения различных вычислений с большими и многомерными массивами данных;
- Возможность преобразования данных;
- Поддержка не только с числовых, но и других типов данных.

Библиотека SciPy - эта библиотека построена на базе NumPy. SciPy отлично подходит для выполнения статистических расчётов и поддерживает те же виды данных, что и библиотека NumPy. Можно сказать, что SciPy - это как "матрешка в матрешке": набор подпакетов, в которых реализованы различные вычислительные механизмы.

SciPy предоставляет все **эффективные численные процедуры**, такие как оптимизация, численное интегрирование и многие другие, с использованием специальных подмодулей. Например, быстрое преобразование Фурье, обработку изображений, решение дифференциальных уравнений, механизмы линейной алгебры и так далее. Благодаря дополнительным пакетам SciPy может решать задачи, которые "не по зубам" NumPy.

SciPy использует массивы NumPy в качестве базовой структуры данных и поставляется с модулями для различных и частоиспользуемых задач в научном программировании.

Библиотеки визуализации данных

Библиотеки для визуализации данных - лучший способ визуально показать содержательные результаты анализа. Эти библиотеки позволяют создавать графики, диаграммы и различные карты.

Пакет Matplotlib - это низкоуровневая библиотека для создания 2D-графиков. С его помощью вы можете создавать различные графики: от гистограмм и диаграмм рассеяния до диаграмм Фейделя.

Библиотека дружелюбна по отношению к другим Python-пакетам, так что вы сможете легко использовать ее вместе с теми же NumPy и SciPy. Более того, Matplotlib поддерживает API, который позволяет встраивать графические объекты в различные приложения. Графические представления данных, создаваемые этим пакетом, поддаются гибкой настройке. Matplotlib поддерживает многие виды графиков и диаграмм, такие как:

- Графики (line plot);
- Диаграммы разброса (scatter plot);
- Столбчатые диаграммы (bar chart) и гистограммы (histogram);

- Круговые диаграммы (pie chart);
- Ствол-лист диаграммы (stem plot);
- Контурные графики (contour plot);
- Поля градиентов (quiver);
- Спектральные диаграммы (spectrogram) и т.д.

Библиотека Seaborn - это API высокого уровня, основанный на библиотеке matplotlib. Она содержит настройки по умолчанию, которые больше подходят для обработки графиков. Кроме того, существует множество библиотек визуализации, включая некоторые сложные типы, такие как временные ряды, диаграммы распределения и скрипичные диаграммы.

Помимо визуализации, эта библиотека неплохо справляется с анализом и исследованием данных. Методы библиотеки позволяют выполнять:

Визуализацию распределения метрических переменных, где используются такие графики, как distplot, jointplot, rugplot, kdeplot. Визуализацию относительно распределения между парами переменных (методы PairGrid, pairplot, FacetGrid). Создание сложных графиков моделей линейной регрессии.

Библиотека Plotly - это популярная библиотека, которая позволяет легко создавать сложную графику. Пакет программного обеспечения подходит для интерактивных веб-приложений и может обеспечивать визуальные эффекты, такие как контурные диаграммы, троичные диаграммы и трехмерные диаграммы.

Эта библиотека позволяет создавать интерактивные графики для последующего анализа взаимоотношений переменных. Пожалуй, ключевым отличием Plotly от Matplotlib является более глубокое, продвинутое построение трёхмерных графиков. Основные возможности:

Визуализация всех необходимых видов графиков:

- линейные диаграммы, круговые диаграммы, пузырьковые диаграммы, точечные диаграммы, древовидные диаграммы;
- Трехмерная визуализация;
- Подготовка интерактивных отчетов и экспорт в формате JSON.

Пакет Bokeh - использует виджеты JavaScript для создания интерактивных и масштабируемых визуализаций в браузере. Библиотека предоставляет множество коллекций диаграмм, возможностей для стилизации, добавления виджетов, определения обратных вызовов и других форм интерактивных возможностей, а также множество других полезных функций.

Bokeh легко интегрируется с любым фреймворком на Python, поддерживает много видов графиков, но самое главное - она позволяет выводить диаграммы и визуальные элементы JavaScript в веб-приложениях.

Да, это можно сделать и в D3.js, но для этого потребуются дополнительные инструменты. В случае Bokeh вы можете просто писать свой код на Python, а библиотека автоматически сгенерирует JavaScript для сайта или приложения. Это открывает огромные интерактивные возможности:

- Поддерживает визуализацию наборов данных, которые обычно используются в статистике и науке;
- Поддерживает различные форматы выходных данных;
- Существуют версии Bokeh для разных языков программирования;

Пакет хорошо интегрируется с такими Python-фреймворками, как Django и Flask.

Алгоритмические библиотеки

Алгоритмические библиотеки решают задачи машинного обучения различной уровни сложности. Мы же рассмотрим два пакета.

Библиотека Scikit-learn содержит инструменты для статистического моделирования и решения задач машинного обучения, включая регрессию, классификацию, кластеризацию и т. д. Это библиотека Python, связанная с NumPy и SciPy. Считается одной из лучших библиотек для работы с комплексными данными. Она построена на библиотеках NumPy, SciPy и Matplotlib.

Scikit-learn – один из самых популярных пакетов для машинного обучения на Python. Встроенные в него модули дают возможность работать с множеством популярных алгоритмов машинного обучения (Machine Learning): алгоритм спектральной кластеризации, кросс-валидация, случайный лес (Random forest), k-средние (K-Means) и так далее. Scikit-learn можно использовать для создания моделей обучения с учителем (Supervised learning) и без.

При этом Scikit-learn абсолютно бесплатный даже для коммерческого использования. Открытый исходный код буквально лежит на GitHub и ждет вас. А чтобы не осталось никаких сомнений – перечислим, какие задачи поддерживает библиотека:

- Предварительная обработка данных;
- Уменьшение размерности;
- Выбор модели;
- Регрессии и классификации;
- Задачи кластеризации.

Библиотека Statsmodels – это модуль Python, который предоставляет множество возможностей для статистического анализа данных, таких как оценка статистической модели и выполнение статистических тестов. С его помощью вы можете реализовать множество методов машинного обучения и изучить возможности рисования.

Пакет выпущен под лицензией Modified BSD с открытым исходным кодом. С его интеграцией не придется ломать голову: для этого можно использовать упомянутый выше Pandas. StatsModels позволяет работать с

- Линейной регрессией;
- Обобщенными линейными моделями и оценочными уравнениями;
- Регрессией с дискретной зависимой переменной;
- Анализом временных рядов и временных моделей методами пространства состояний statespace;
- Таблицами непредвиденных обстоятельств;
- Множественными расчетами с цепными уравнениями.