Регрессионный анализ данных. Часть 1.

- Понятие регрессионного анализа. Построение регрессионной модели.
- Применение регрессионного анализа для решения образовательных задач: прогнозирование успеваемости, оценка эффективности обучения, выявление факторов успеха.
- Простая линейная регрессия. Построение линейной регрессии. Критерии оценки качества полученной модели.
- Построение множественной линейной регрессии.
- Регуляризация моделей. L1, L2 - регуляризация. Выбор коэффициента регуляризации.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

np.set_printoptions(precision=2)
plt.style.use('ggplot')
```

1. Понятие регрессионного анализа. Построение регрессионной модели.

К задачам регрессионного анализа данных относятся задачи, в которых на основании ранее полученных данных наблюдения требуется исследовать/построить зависимости одних показателей от других. В этой теме мы рассмотрим задачи построения линейных регрессионных зависимостей.

Мы предполагаем модель образования данных вида

$$y_i = f(x^{(i)}) + \varepsilon_i$$

Наша задача восстановить неизвестную зависимость $f(x)$. Для решения этой задачи обычно используют критерий L_2 -аппроксимации (критерий наименьших квадратов):

$(L_2)\ \Phi 2(\hat{f}) = \sum_{i=1..n} (y_i - \hat{f}(x^{(i)}))^2 = \sum_{i=1..n} \varepsilon_i^2 \to min.$

Данный критерий ошибки аппроксимации соответствует минимальному по длине вектору ошибки ε:

$$|\varepsilon|^2 = \sum_{i=1..n} \varepsilon_i^2$$

Таким образом, мы можем сформулировать задачу аппроксимации следующим образом - "выбрать из некоторого множества возможных функций K_f ту, которая лучше всего описывает данные с точки зрения выбранного критерия $\Phi 2()$:"

$$\hat{f}^* = arg \min_{\hat{f} \in K_f} \Phi 2(\hat{f})$$

2. Пример задачи регрессионного анализа: прогнозирование успеваемости.

В качестве примера рассмотрим реальную задачу прогноза итогового балла на онлайн-курсе по известным результатам выполнения заданий первой половины курса.

В практике онлайн-обучения есть несколько важных метрик оценки качества обучения. Одна из основных метрик - это процент удержания на курсе и процент завершения курса

- процент удержания на курсе (retention rate) - какой % студентов из начавших обучаться на курсе остались учиться на экваторе курса;
- процент завершения курса (completion rate) - какой % студентов из начавших обучаться на курсе завершили успешно курс;

Поэтому важно уметь прогнозировать итоговый балл студентов на курсе, чтобы понять преодолеют ли они порог успешного завершения курса.

Это оценку можно выполнить, если известны текущие их набранные баллы за работы на курсе. Обычно прогноз делаю на середине курса по полученным к этому времени результатам.

Данные с онлайн-курса для обучения модели

Возьмем достаточно простой онлайн-курс "Академия онлайн-обучения-1 ступень" для преподавателей, который был открыт в 2019 году. Он состоял из 8 тем и в каждой теме был итоговый тест. Таким образом в качестве половины курса можно рассматривать завершение первых четырех тем/тестов.

Но, чтобы построить модель, нам необходмио также знать подсказки для модели - ответы, итоговые баллы обучающихся, которые мы хотим прогнозировать и на основе которых мы будет обучать модель. Это называется **размеченные данные**. Эти данные делят на две части: обучающую и тестовые выборки. На обучающей выборке (60-90 % размеченных данных) модель обучают, а на тестовых данных проверяют ее точность

Модель будем строить в таком виде:

$$y_M(x_1, x_2, x_3, x_4) = a_0 + a_1 * x_1 + a_2 * x_2 + a_3 * x_3 + a_4 * x_4.$$

Здесь x_i - это баллы учащегося за тест i-й темы, y - итоговый балл, y_M - итоговый балл, предсказанный моделью.

Наша задача - подобрать коэффициенты a_1, a_2, a_3, a_4 так чтобы прогноз модели был "как можно ближе" к реальным суммарным баллам обучающихся:

$$\Phi 2(\bar{a}) = \sum_{j=0}^{n} (y_j - y_M[j])^2 \to min;$$

или

$$\Phi 2(\bar{a}) = \sum_{j=0}^{n} (y_j - (a_0 + a_1 * x_1[j] + a_2 * x_2[j] + a_3 * x_3[j] + a_4 * x_4[j]))^2 \to min.$$

Здесь $x_i[j]$ - это баллы j-го учащегося за тест i-й темы.

```
# подключаем наш диск
from google.colab import drive
drive.mount('/content/drive')

# Указываем путь к файлу с данными  !!!
dir_path = "/content/drive/My Drive/Colab Notebooks/teacher/COMP_MATH/Cases/case-4/"
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=Tr
```

```
# загрузим данные - результаты выполнения заданий на онлайн-курсе КПК "Академия онлайн-обучения"
course_file_name = "online_acad_lin"
csv_file_path = dir_path + course_file_name + ".csv"

data = pd.read_csv(csv_file_path, sep=';' )
data.tail(10)
```

	0	1	2	3	sum
888	10.00	9.63	8.44	10.0	45.93
889	0.00	0.00	0.00	0.0	0.00
890	8.81	9.63	8.02	10.0	61.53
891	6.86	9.04	9.17	10.0	68.31
892	10.00	10.00	9.75	10.0	76.19
893	0.00	0.00	0.00	0.0	0.00
894	8.52	9.72	8.33	10.0	53.89
895	8.52	9.04	9.33	10.0	54.11
896	7.33	6.93	0.00	10.0	57.45
897	0.00	10.00	10.00	0.0	20.00

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 898 entries, 0 to 897
Data columns (total 5 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   0       898 non-null    float64
 1   1       898 non-null    float64
 2   2       898 non-null    float64
 3   3       898 non-null    float64
 4   sum     898 non-null    float64
dtypes: float64(5)
memory usage: 35.2 KB
```

видим, что эти данные уже подготовлены, отсутствующие баллы заменены на 0. Можно отфильтровать "нулевых" учащихся, которые не набрали ни одного балла и, скорее всего, просто не приступили к обучению.

```
data = data[data['sum'] > 0]
data.tail(10)
```

	0	1	2	3	sum
886	10.00	10.00	9.75	10.0	73.84
887	5.76	6.70	8.44	10.0	66.48
888	10.00	9.63	8.44	10.0	45.93
890	8.81	9.63	8.02	10.0	61.53
891	6.86	9.04	9.17	10.0	68.31
892	10.00	10.00	9.75	10.0	76.19
894	8.52	9.72	8.33	10.0	53.89
895	8.52	9.04	9.33	10.0	54.11
896	7.33	6.93	0.00	10.0	57.45
897	0.00	10.00	10.00	0.0	20.00

```
# первичный анализ данных
data.describe()
```

	0	1	2	3	sum
count	733.000000	733.000000	733.000000	733.000000	733.000000
mean	8.706235	8.514134	7.951501	7.958677	58.564816
std	1.699112	2.162328	2.443024	3.401687	18.450274
min	0.000000	0.000000	0.000000	0.000000	1.480000
25%	8.100000	8.110000	7.420000	8.130000	53.980000
50%	9.290000	9.260000	8.630000	9.630000	64.410000
75%	10.000000	10.000000	9.500000	10.000000	70.680000
max	10.000000	10.000000	10.000000	10.000000	80.000000

Подготовка данных для обучения модели

Для построения адекватной, непереобученной модели необходимо:

- выделить из массива данных матрицу значений предикторов X и значений выходной переменной в вектор Y;
- разделить исходную выборку на две части – обучающую и тестовую.

На обучающей выборке мы будем строить/обучать модель. На тестовой выборке – проверять ее точность. Это позволит нам оценить и сравнить разные модели и выбрать лучшую.

```
# выделяем массив значений предиктивных переменных и выходной переменной
Xm = data.iloc[:,:-1]
Y = data.iloc[:,-1:]
Xm.shape, Y.shape
```

```
((733, 4), (733, 1))
```

```
from sklearn.model_selection import train_test_split

# Выделяем часть данных для обучения (70%), а часть - для проверки точности модели (30%)
x_train, x_test, y_train, y_test = train_test_split(Xm, Y, train_size=0.7, random_state=42)
x_train.shape, x_test.shape, y_train.shape, y_test.shape
```

```
((513, 4), (220, 4), (513, 1), (220, 1))
```

3. Построение простой линейной регрессии без дополнительных предикторов

Т.е. будем строить простую модель вида:

$$y_m(\bar{x}) = a_0 + a_1 * x_1 + \ldots + a_4 * x_4$$

```
from sklearn.linear_model import LinearRegression
```

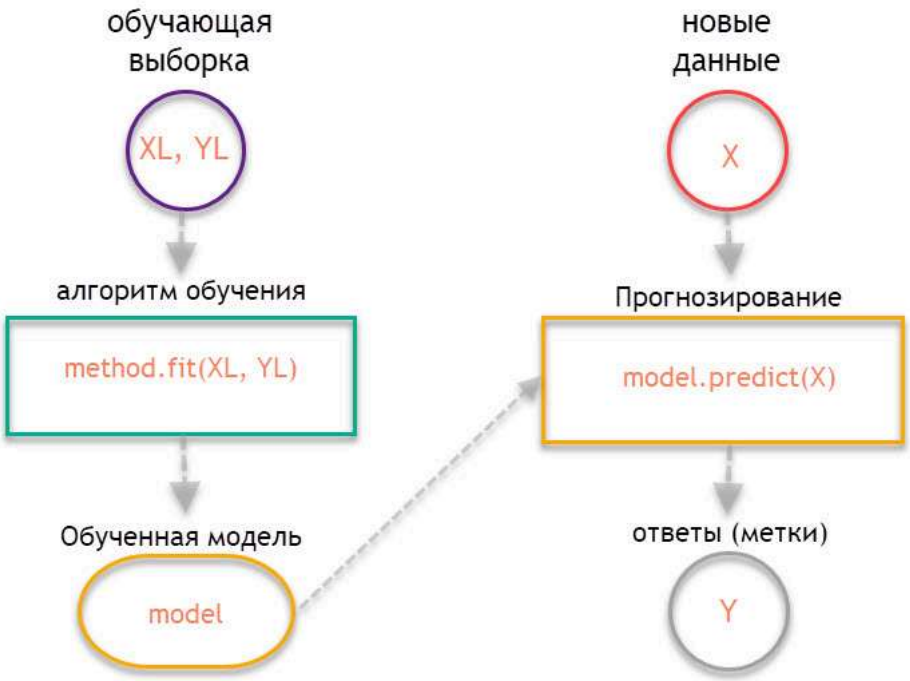


```
# создаем объект класса линейная регрессия
lin_reg = LinearRegression( )

# Обучаем модель на обучающей выборке
model = lin_reg.fit(x_train, y_train)

# выводим полученные коэффициент модели
print('a0=', model.intercept_)
print(model.coef_)
```

```
a0= [-4.02]
[[1.51 1.11 1.84 3.16]]
```

Критерии оценки качества полученной модели.

Метрики оценки регрессионных моделей определяют качество прогнозирования числовых значений, измеряя разницу между предсказанными ($\hat{y}_j$) и фактическими данными (y_j).

Основные метрики — MAE (средняя абсолютная ошибка), MSE (среднеквадратичная ошибка), RMSE (корень из MSE) и (R^{2}) (коэффициент детерминации), где меньшие значения ошибок (MAE, MSE, RMSE) и (R^{2}) ближе к 1 указывают на более точную модель

Основные метрики регрессии

1. **MAE** (Mean Absolute Error) — Средняя абсолютная ошибка: Среднее арифметическое модулей отклонений предсказаний от факта.

   > Особенность: Интерпретируема в тех же единицах, что и целевая переменная. Устойчива к выбросам.
   > Формула:
   > $$MAE = \frac{1}{n}\sum_{j=1}^{n}|y_j - \hat{y}_j|$$

2. **MSE** (Mean Squared Error) — Среднеквадратичная ошибка: Среднее арифметическое квадратов разностей между фактом и прогнозом.

   > Особенность: Сильно штрафует модель за большие ошибки (из-за возведения в квадрат). Формула:
   > $$MSE = \frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2$$

3. **RMSE** (Root Mean Squared Error) — Корень из MSE.

   > Особенность: Также штрафует за большие ошибки, но, в отличие от MSE, измеряется в тех же единицах, что и целевая переменная.

4. R^2 (R-squared) — Коэффициент детерминации: Доля дисперсии целевой переменной, объясненная моделью.

> Особенность: Показывает качество модели относительно «наивного» прогноза (среднего значения). (R^2 = 1) — идеальная модель, (R^2 < 0) — модель хуже, чем просто среднее.

5. **MAPE** (Mean Absolute Percentage Error) — Средняя абсолютная процентная ошибка: Среднее процентное отклонение прогноза от факта.

> Особенность: Удобна для интерпретации качества в процентах, но не работает, если фактические значения равны 0.

Оценим полученную модель с помощью данных метрик. Модель оцениваем на тестовой выборке. Для этого надо рассчитать ее прогноз на тестовой выборке.

```
from sklearn import metrics

# расчет прогноза модели на тестовой выборке
y_predicted = model.predict(x_test)

# сравниваем прогноз и реальный суммарный балл с испльзованием метрик
print('MAE - Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_predicted))
print('MSE - Mean Squared Error:', metrics.mean_squared_error(y_test, y_predicted))
print('RMSE - Root Mean Squared Error:', metrics.root_mean_squared_error(y_test, y_predicted))
print('r2_score:', metrics.r2_score(y_test, y_predicted))
print('MAPE - Mean Absolute Percentage Error:', metrics.mean_absolute_percentage_error(y_test, y_predicted))
```

```
MAE - Mean Absolute Error: 5.712241455568111
MSE - Mean Squared Error: 53.646711786978166
RMSE - Root Mean Squared Error: 7.324391564285607
r2_score: 0.7878709059630407
MAPE - Mean Absolute Percentage Error: 0.10882031926037974
```

анализ показывает, что:

- наша ошибка прогноза составляет примерно 10% (MAPE = 0.1);
- модель объясняет примерно 79 % разброса значений y. Это достаточно хорошое качество модели;
- в среднем мы отклоняемся от истинного значения суммарного балла на 5.7 балла (MAE=5.7) при максимальном значении его 80.

```
fig = plt.figure(figsize=(6, 6))
#plt.plot(_X, y_test, c='b', label='original')
plt.scatter(y_test, y_predicted, c='r', marker='o', label='predicted-original')
plt.xlabel('$y_i(original)$'); plt.ylabel('$ym_i(predicted)$')
plt.plot([0, 80], [0, 80], 'b--')
plt.title('Анализ отклонения прогноза от реальных данных');
```

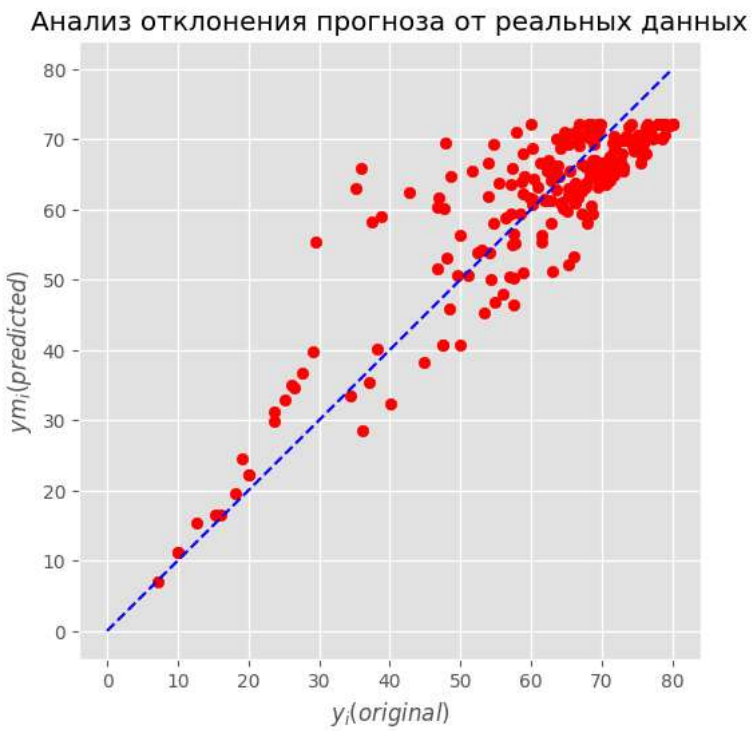

4. Добавление в модель предикторов

Чтобы учесть нелинейные эффекты выполнения тестов добавим в модель слагаемые взаимодействия признаков/переменных:

$$y_m(\bar{x}) = a_0 + a_1 * x_1 + \ldots + a_4 * x_4 + a_5 * x_1 * x_1 + a_6 * x_1 * x_2 + ..$$

```
from sklearn.preprocessing import PolynomialFeatures

poly = PolynomialFeatures(degree=2) # указывать большую степень нет смысла

# добавляем предикторов в матрицы предикторов
x_train_poly = poly.fit_transform(x_train)
x_test_poly = poly.fit_transform(x_test)

x_train_poly.max()
```

```
np.float64(100.0)
```

```
# нормируем значения X_i, чтобы они все были в одинаковом интервале значений
from sklearn.preprocessing import StandardScaler, MinMaxScaler, MaxAbsScaler, Normalizer, RobustScaler

# нормируем значения X
scaler = MinMaxScaler()
# x_train_poly = scaler.fit_transform(x_train_poly)
```

```
# создаем объект класса линейная регрессия
lin_reg = LinearRegression( )

# Обучаем модель на обучающей выборке
model_poly = lin_reg.fit(x_train_poly, y_train)

# выводим полученные коэффициент модели
print('a0=', model_poly.intercept_)
print(model_poly.coef_)
```

```
a0= [-1.58]
[[ 0.    1.62  1.56  1.07  3.86 -0.05  0.08 -0.03  0.06 -0.13  0.09  0.12
   0.03  0.02 -0.24]]
```

```
# x_test_poly = scaler.transform(x_test_poly)

# расчет прогноза модели на тестовой выборке
y_pred = model_poly.predict(x_test_poly)

# сравниваем прогноз и реальный суммарный балл с испльзованием метрик
print('MAE - Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_pred))
print('r2_score:', metrics.r2_score(y_test, y_pred))
print('MAPE - Mean Absolute Percentage Error:', metrics.mean_absolute_percentage_error(y_test, y_pred))
```

```
MAE - Mean Absolute Error: 5.602581287890985
r2_score: 0.7924648900861628
MAPE - Mean Absolute Percentage Error: 0.10577379653113407
```

5. L1, L2-регуляризация

Если наша модель слишком сложна и может переобучиться на обучающей выборке, то имеет смысл применить регуляризацию - добавление требования более спокойной модели за счет уменьшения абсолютных значений параметров модели.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score

# 1. Generate synthetic data
np.random.seed(42)
X_synth = np.sort(np.random.rand(30) * 10).reshape(-1, 1)
y_synth = np.sin(X_synth).ravel() + np.random.normal(0, 0.5, size=X_synth.shape[0])

# 2. Split synthetic data into training and testing sets
X_train_synth, X_test_synth, y_train_synth, y_test_synth = train_test_split(X_synth, y_synth, test_size=0.3, random_state

# Function to train and evaluate polynomial models
def plot_polynomial_regression(degree, X_train, y_train, X_test, y_test, ax, plot_title):
```

```
        poly = PolynomialFeatures(degree=degree)
        X_train_poly = poly.fit_transform(X_train)
        X_test_poly = poly.transform(X_test)

        lin_reg_model = LinearRegression()
        lin_reg_model.fit(X_train_poly, y_train)

        y_train_pred = lin_reg_model.predict(X_train_poly)
        y_test_pred = lin_reg_model.predict(X_test_poly)

        # Evaluate metrics
        train_mse = mean_squared_error(y_train, y_train_pred)
        test_mse = mean_squared_error(y_test, y_test_pred)
        train_r2 = r2_score(y_train, y_train_pred)
        test_r2 = r2_score(y_test, y_test_pred)

        # Plotting
        ax.scatter(X_train, y_train, s=10, label='Train data', alpha=0.6)
        ax.scatter(X_test, y_test, s=10, label='Test data', alpha=0.6)

        # Sort X_synth to plot the prediction line smoothly
        X_plot = np.arange(np.min(X_synth), np.max(X_synth) + 0.1, 0.2).reshape(-1, 1)
        X_plot_poly = poly.transform(X_plot)
        y_plot_pred = lin_reg_model.predict(X_plot_poly)
        ax.plot(X_plot, y_plot_pred, color='red', label=f'Model (Degree {degree})')

        ax.set_title(f'{plot_title}\nTrain MSE: {train_mse:.2f}, Test MSE: {test_mse:.2f}\nTrain R2: {train_r2:.2f}, Test R2:
        ax.legend()
        ax.set_ylim(-2.5, 2.5)

    # 3. Train and visualize models with different degrees
    fig, axes = plt.subplots(1, 3, figsize=(18, 5), sharey=True)

    # Underfitting model (degree 1)
    plot_polynomial_regression(1, X_train_synth, y_train_synth, X_test_synth, y_test_synth, axes[0], 'Underfitting (Degree 1)

    # Good fit model (degree 4)
    plot_polynomial_regression(4, X_train_synth, y_train_synth, X_test_synth, y_test_synth, axes[1], 'Good Fit (Degree 4)')

    # Overfitting model (degree 10)
    plot_polynomial_regression(10, X_train_synth, y_train_synth, X_test_synth, y_test_synth, axes[2], 'Overfitting (Degree 10

    plt.tight_layout()
```

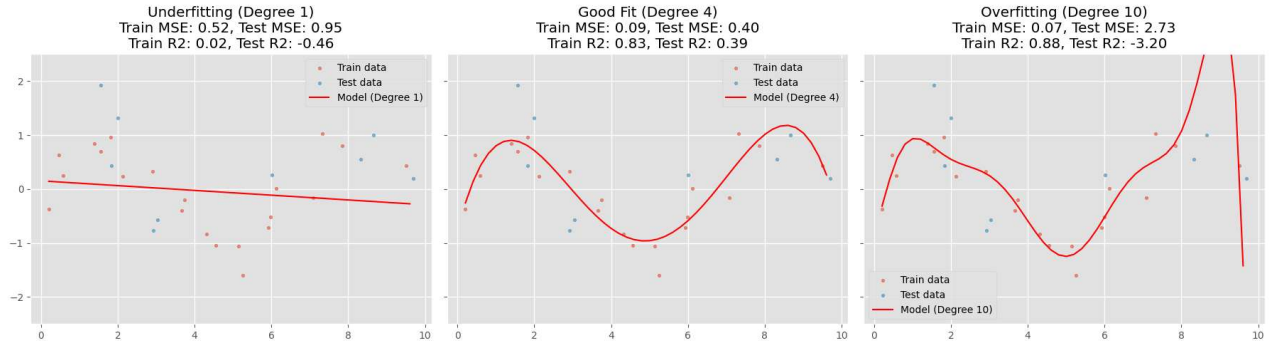

L2 - регуляризация или гребневая регрессия

$$\Phi 2(\bar{a}) = \sum_{j=0}^{n} (y_j - y_M[j])^2 + \alpha \sum_{i=1}^{m} a_i^2 \to min;$$

α - коэффициент регуляризации.

Применим L2-регуляризацию для построения модели в нашем примере.

```
# L2 - регуляризация или гребневый метод
from sklearn.linear_model import Ridge

ridge_reg = Ridge(alpha=0.1)
model2 = ridge_reg.fit(x_train_poly, y_train)
print('a0=', model2.intercept_)
print(model2.coef_)

# проанализируем насколько хорошо получилось
y_predicted = model2.predict(x_test_poly)

# сравниваем прогноз и реальный суммарный балл с испльзованием метрик
print('MAE - Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_predicted))
print('r2_score:', metrics.r2_score(y_test, y_predicted))
print('MAPE - Mean Absolute Percentage Error:', metrics.mean_absolute_percentage_error(y_test, y_predicted))
```

```
a0= [-1.58]
[ 0.    1.62  1.56  1.08  3.86 -0.05  0.08 -0.03  0.06 -0.13  0.09  0.12
  0.03  0.02 -0.24]
MAE - Mean Absolute Error: 5.602961828223456
r2_score: 0.792446005509007
MAPE - Mean Absolute Percentage Error: 0.105783647165559
```

ничего L2- регуляризация в данном случае не дала/

L1-регуляризация или метод LASSO

$$\Phi 2(\bar{a}) = \sum_{j=0}^{n}(y_j - y_M[j])^2 + \alpha \sum_{i=1}^{m}|a_i| \to min;$$

α - коэффициент регуляризации.

Применим L2-регуляризацию для построения модели в нашем примере.

```
from sklearn.linear_model import Lasso

method = Lasso(alpha=0.4)
model3 = method.fit(x_train_poly, y_train)
print('a0=', model3.intercept_)
print(model3.coef_)

# проанализируем насколько хорошо
y_predicted = model3.predict(x_test_poly)

# сравниваем прогноз и реальный суммарный балл с испльзованием метрик
print('MAE - Mean Absolute Error:', metrics.mean_absolute_error(y_test, y_predicted))
print('r2_score:', metrics.r2_score(y_test, y_predicted))
print('MAPE - Mean Absolute Percentage Error:', metrics.mean_absolute_percentage_error(y_test, y_predicted))
```

```
a0= [6.83]
[ 0.    0.    0.95  0.15  3.79  0.02  0.02  0.13  0.04 -0.    0.03  0.06
  0.03  0.02 -0.17]
MAE - Mean Absolute Error: 5.6141640058856845
r2_score: 0.7953182383329905
MAPE - Mean Absolute Percentage Error: 0.10581578451374073
```

Видим, что точность модели повысилась

```
from sklearn.linear_model import Ridge, Lasso

alphas = np.logspace(-3, 1, 100) # Generate 100 alpha values from 10^-4 to 10^2

ridge_coefs = []
lasso_coefs = []

for a in alphas:
    ridge = Ridge(alpha=a, max_iter=10000)
    ridge.fit(x_train_poly, y_train)
    ridge_coefs.append(ridge.coef_)

    lasso = Lasso(alpha=a, max_iter=10000)
    lasso.fit(x_train_poly, y_train)
    lasso_coefs.append(lasso.coef_)

ridge_coefs = np.array(ridge_coefs)
lasso_coefs = np.array(lasso_coefs)
```

```
plt.figure(figsize=(10, 4))
```

```
plt.subplot(1, 2, 1)
plt.plot(alphas, ridge_coefs)
plt.xscale('log')
plt.xlabel('Alpha')
plt.ylabel('Coefficient Value')
plt.title('Ridge Regression Coefficients vs. Alpha')
plt.grid(True)

plt.subplot(1, 2, 2)
plt.plot(alphas, lasso_coefs)
plt.xscale('log')
plt.xlabel('Alpha')
plt.ylabel('Coefficient Value')
plt.title('Lasso Regression Coefficients vs. Alpha')
plt.grid(True)

plt.tight_layout()
plt.show()
```

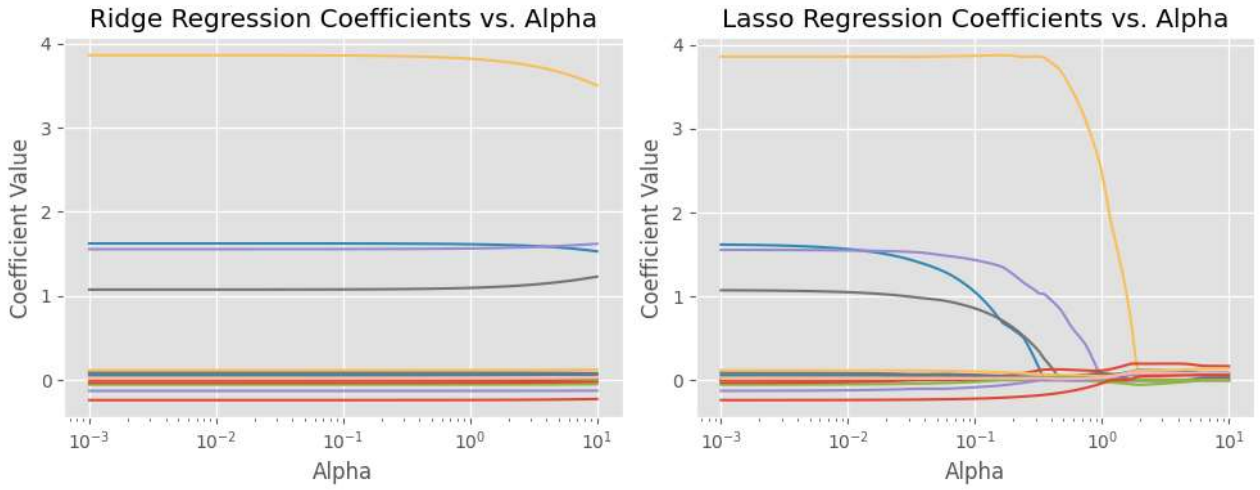

ВЫВОДЫ

- часто перед исследователем стоит задача оценить связь между параметрами процесса; понять как входные параметры процесса (обучения) влияют на итоговый результат; в этом случае применяют регрессионный анализ;
- регрессионный анализ – это процесс построения модели, функциональной зависимости выходнрой (зависимой) переменной от предикторов (входных переменных);
- после того, как мы определили вид модели (состав модели), осуществляется ее обучение – подгонка ее параметров под обучающую выборку;
- проверяют точность и качество модели всегда на дополнительной, тестовой выборке, на которой модель не обучалась;
- регуляризация помогает предотвратить переобучение модели – ее перенастройку на обучающую выборку.